Alex Hsiao （Wei-Chun Hsiao）

FULL-STACK GENAI ENGINEER

目前于大同世界科技担任 **全栈 GenAI 工程师**，实践经验涵盖全栈应用开发、LLM Agent 与 RAG 检索流程、容器化 GPU 基础设施（NVIDIA GPU Operator 与 HAMi）、以 LangGraph 构建有状态的多代理 LLM、分布式微服务，以及 ISO/IEC 27001 安全合规。

1M tokens · 单张 H100 可用上下文　**0** 漏洞 · 6 个硬化镜像　**95.3%** AI Agent 准确率 · 300 题

MAIL
q123717111@gmail.com

TEL
+886 0970-565-709

LOC
台北，台湾 · UTC+8

WEB
blog.alextrinitywolf.com

GITHUB
github.com/AlexTrinityBlock

STATUS
ONLINE // 开放资深职位

工作经历

2025 年 11 月 – 至今
大同世界科技（Tatung System Technologies）
全栈 GenAI 工程师
台北市中山区

- 为房地产租赁业客户构建企业级房地产租赁管理系统，含 13 个功能模块与 21 个侧边栏页面，从系统设计、应用开发到基础设施建设全程负责：混合 AI Agent、文档搜索、工具调用、横跨 8 类业务实体的向量与 BM25（PGroonga）混合检索 **RAG**、S3 兼容文件管理、GIS 地理坐标、Agent 式 SQL 查询，以及 Agent 自动评测；并以双层防护（Row-Level Security 与只读数据库账号）管控数据访问。
- 构建公司内部的物料自动化系统，自动判读采购单与报价单并转换为 SAP 物料主档数据，取代 113 位使用者的人工逐笔录入：AI 提取中位数 41 秒，人工约需 15 分钟（约 22 倍速；22 笔批次中 4 笔转人工复核）。
- 在单张 H100 上把 120B 模型的可用上下文从约 30K 提升到 1M tokens：将 KV Cache 卸载至 CPU RAM（140 GB），搭配 FP8 KV Cache 量化与 Multi-Token Prediction 投机解码；实测单请求 990,016 tokens，10 次全部成功、零抢占。
- 在客户的 **RTX PRO 6000** GPU 上部署本地 LLM 并支持 Multi-Token Prediction，于同一个 Kubernetes 集群上以多卡并行运行 vLLM 与 llama.cpp 提供推理服务。

技术栈 · React.js、FastAPI、LangGraph、vLLM、llama.cpp、Azure OpenAI、PGroonga、Valkey、RabbitMQ、PostgreSQL、Kubernetes、Kubespray、Helm、NVIDIA GPU Operator、HAMi、Longhorn、CrowdSec、OpenBao

---

2025 年 9 月 – 2026 年 6 月
国立嘉义大学 AIGC 研究社
社团指导老师 / 专业技术顾问（Faculty Advisor）
嘉义市

- 在社团草创期受邀担任指导老师与专业讲师，协助定义 AIGC 技术研究方向与学术伦理规范。

2025 年 3 月 – 2025 年 11 月（9 个月）
国家资通安全研究院（NICS）
软件工程师
台北市中正区

- 推动云安全计划，直接参与国家基础设施的 **AWS 政府配置基线（GCB）**制定。
- 研究并实现以 LangGraph 与多代理 LLM 为核心的前沿 AI 功能与自主工作流。

技术栈 · Python、Next.js、LangGraph、FastAPI、CloudFormation、MongoDB、AWS 安全基线

2024 年 6 月 – 2025 年 3 月（10 个月）
云服务代理商
项目工程师 / 软件工程师
台北市南港区

- 规划并实现企业级 GCP 与 AWS 云环境，执行复杂的跨云迁移并配置安全的站点到站点 VPN。
- 设计集中式监控平台，部署具备精细 RBAC 策略的生产 Kubernetes 集群。

技术栈 · Kubernetes、GCP、AWS、Terraform、Ansible、WAF、云架构

2021 年 9 月 – 2023 年 10 月（2 年 2 个月）
国立嘉义大学信息工程学系信息安全实验室
硕士研究员 / 项目助理
嘉义市

- 从事深度学习与网络安全入侵检测研究，聚焦 Web 应用安全。
- 设计结合多模型 CNN、双向 GRU 与多头自注意力的混合架构，用于 SQLi 与 XSS 攻击检测。

技术栈 · Python、PyTorch、TensorFlow、Django、Flask、深度学习、IEEE 论文

2019 年 12 月 – 2020 年 3 月（4 个月）

Ticrown Asset Management Ltd.

PHP 助理工程师 / 网页设计

高雄市大寮区

- 参与集装箱运输企业的 PHP Laravel 物流管理系统开发与界面实现。

技术栈 · PHP、Laravel、MySQL、JavaScript、CSS

技术能力

GenAI 与机器学习

vLLM 推理引擎 · LangGraph 多代理系统 · RAG 混合检索 · LLM Agent 评测 · HAMi vGPU 切分 · NVIDIA GPU Operator · PyTorch 与 TensorFlow

全栈与分布式系统

FastAPI / Python · Node.js（异步运行时） · RabbitMQ（AMQP 消息中间件） · Django / Flask · PHP / Laravel

云架构与编排

Kubernetes（CKA 认证） · AWS 云（SAP 认证） · Google Cloud（PCA 认证） · Terraform（IaC 自动化） · Docker 与 Podman

数据库与韧性存储

PostgreSQL · Microsoft SQL Server · MongoDB 与 MySQL · Longhorn 高可用块存储 · MinIO / S3 Parquet

认证与论文



NVIDIA 生成式 AI 大语言模型专业认证

NVIDIA // CREDLY VERIFIED · 验证



Kubernetes 管理员认证（CKA）

LINUX FOUNDATION / CNCF · 验证



AWS 解决方案架构师 – 专业级（SAP）

AMAZON WEB SERVICES · 验证



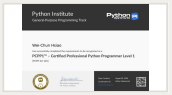
Google Cloud 专业云架构师（PCA）

GOOGLE CLOUD · 验证



ISO/IEC 27001 信息安全主任审核员

TKSG // ISMS GOVERNANCE · 验证



PCPP1™ – Python 专业程序员认证 Level 1

OPENEDG PYTHON INSTITUTE // CREDLY VERIFIED · 验证



IEEE Xplore：SQLi 与 XSS 深度学习检测论文

IEEE XPLORE // PEER REVIEWED · 验证

学历

国立嘉义大学 信息工程学系 硕士

硕士论文发表于 IEEE Xplore（文献 10210155）：结合 CNN、BiGRU 与多头自注意力之 SQLi／XSS 检测架构。