Alex Hsiao （Wei-Chun Hsiao）

FULL-STACK GENAI ENGINEER

目前於大同世界科技擔任 **全端 GenAI 工程師**，實務經驗涵蓋全端應用開發、LLM Agent 與 RAG 檢索流程、容器化 GPU 基礎設施（NVIDIA GPU Operator 與 HAMi）、以 LangGraph 打造具狀態的多代理 LLM、分散式微服務，以及 ISO/IEC 27001 安全合規。

1M tokens · 單張 H100 可用上下文　**0** 漏洞 · 6 個硬化映像　**95.3%** AI Agent 準確率 · 300 題

MAIL
q123717111@gmail.com

TEL
+886 0970-565-709

LOC
台北，台灣 · UTC+8

WEB
blog.alextrinitywolf.com

GITHUB
github.com/AlexTrinityBlock

STATUS
ONLINE // 開放資深職缺

工作經歷

2025 年 11 月 – 迄今
大同世界科技（Tatung System Technologies）
全端 GenAI 工程師
台北市中山區

- 為房地產租賃業客戶建置企業級房地產租賃管理系統，含 13 個功能模組與 21 個側邊欄頁面，從系統設計、應用開發到基礎設施建置全程負責：混合 AI Agent、文件搜尋、工具呼叫、橫跨 8 類業務實體的向量與 BM25（PGroonga）混合檢索 **RAG**、S3 相容檔案管理、GIS 地理座標、Agent 式 SQL 查詢，以及 Agent 自動評測；並以雙層防護（Row-Level Security 與唯讀資料庫帳號）管制資料存取。
- 建置公司內部的物料自動化系統，自動判讀採購單與報價單並轉換為 SAP 物料主檔資料，取代 113 位使用者的人工逐筆輸入：AI 提取中位數 41 秒，人工約需 15 分鐘（約 22 倍速；22 筆批次中 4 筆轉人工複核）。
- 在單張 H100 上把 120B 模型的可用上下文從約 30K 提升到 1M tokens：將 KV Cache 卸載至 CPU RAM（140 GB），搭配 FP8 KV Cache 量化與 Multi-Token Prediction 投機解碼；實測單一請求 990,016 tokens，10 次全數成功、零搶占。
- 在客戶的 **RTX PRO 6000** GPU 上部署本地 LLM 並支援 Multi-Token Prediction，於同一個 Kubernetes 叢集上以多卡平行執行 vLLM 與 llama.cpp 提供推論服務。

技術棧 · React.js、FastAPI、LangGraph、vLLM、llama.cpp、Azure OpenAI、PGroonga、Valkey、RabbitMQ、PostgreSQL、Kubernetes、Kubespray、Helm、NVIDIA GPU Operator、HAMi、Longhorn、CrowdSec、OpenBao

2026 年 9 月 – 2026 年 12 月（進行中）
大數智能教育（Gtalent Education）
NVIDIA NCA-GENL 生成式 AI 助理級證照班 講師
線上直播

- 講授 NVIDIA NCA-GENL 生成式 AI 助理級證照課程：5 篇章、32 堂各 1 小時的線上直播課，週末授課（截至 2026 年 11 月已完成 15 堂）。

2025 年 9 月 – 2026 年 6 月
國立嘉義大學 AIGC 研究社
社團指導老師 / 專業技術顧問（Faculty Advisor）
嘉義市

- 於社團草創期受邀擔任指導老師與專業講師，協助定義 AIGC 技術研究方向與學術倫理規範。

2025 年 3 月 – 2025 年 11 月（9 個月）
國家資通安全研究院（NICS）
軟體工程師
台北市中正區

- 推動雲端安全計畫，直接參與國家基礎設施的 **AWS 政府組態基準（GCB）**制定。
- 研究並實作以 LangGraph 與多代理 LLM 為核心的前沿 AI 功能與自主工作流程。

技術棧 · Python、Next.js、LangGraph、FastAPI、CloudFormation、MongoDB、AWS 安全基準

2024 年 6 月 – 2025 年 3 月（10 個月）
雲端服務代理商
專案工程師 / 軟體工程師
台北市南港區

- 規劃並實作企業級 GCP 與 AWS 雲端環境，執行複雜的跨雲遷移並配置安全的站對站 VPN。
- 設計集中式監控平台，部署具細緻 RBAC 策略的生產 Kubernetes 叢集。

技術棧 · Kubernetes、GCP、AWS、Terraform、Ansible、WAF、雲端架構

2021 年 9 月 – 2023 年 10 月（2 年 2 個月）

國立嘉義大學資訊工程學系 資訊安全實驗室

碩士研究員 / 專案助理

嘉義市

- 從事深度學習與網路安全入侵偵測研究，聚焦網頁應用安全。
- 設計結合多模型 CNN、雙向 GRU 與多頭自注意力的混合架構，用於 SQLi 與 XSS 攻擊偵測。

技術棧 · Python、PyTorch、TensorFlow、Django、Flask、深度學習、IEEE 論文

技術能力

GenAI 與機器學習

vLLM 推論引擎 · LangGraph 多代理系統 · RAG 混合檢索 · LLM Agent 評測 · HAMi vGPU 切分 · NVIDIA GPU Operator · PyTorch 與 TensorFlow

全端與分散式系統

FastAPI / Python · Node.js（非同步執行環境） · RabbitMQ（AMQP 訊息中介） · Django / Flask · PHP / Laravel

雲端架構與編排

Kubernetes（CKA 認證） · AWS 雲端（SAP 認證） · Google Cloud（PCA 認證） · Terraform（IaC 自動化） · Docker 與 Podman

資料庫與韌性儲存

PostgreSQL · Microsoft SQL Server · MongoDB 與 MySQL · Longhorn 高可用區塊儲存 · MinIO / S3 Parquet

認證與論文



NVIDIA 生成式 AI 大型語言模型專業認證
NVIDIA // CREDLY VERIFIED · 驗證



Kubernetes 管理員認證（CKA）
LINUX FOUNDATION / CNCF · 驗證



AWS 解決方案架構師 – 專業級（SAP）
AMAZON WEB SERVICES · 驗證



Google Cloud 專業雲端架構師（PCA）
GOOGLE CLOUD · 驗證



ISO/IEC 27001 資訊安全主導稽核員
TKSG // ISMS GOVERNANCE · 驗證



PCPP1™ – Python 專業程式設計師認證 Level 1
OPENEDG PYTHON INSTITUTE // CREDLY VERIFIED · 驗證



IEEE Xplore：SQLi 與 XSS 深度學習偵測論文
IEEE XPLORE // PEER REVIEWED · 驗證

學歷

國立嘉義大學 資訊工程學系 碩士

碩士論文發表於 IEEE Xplore（文獻 10210155）：結合 CNN、BiGRU 與多頭自注意力之 SQLi／XSS 偵測架構。